

Relatório Técnico: Implementação de Biblioteca para Análise

Estatística e Mineração de Dados

Autores: Eli Barreto, Elias Barreto, Emerson Lucas

Centro Universitário de Excelência (UNEX)

Av. Artêmia Pires Freitas, s/n - Sim, Feira de Santana - BA, 44085-370

eliklebercb@gmail.com, 241030866@aluno.unex.edu.br,
eliasguideonbarreto@gmail.com

Abstract. *This report introduces the "Dende Statistics" library, developed in native Python for data mining. It focuses on implementing statistical and logical operators for central tendency, dispersion, frequencies, and probabilities. The tool features ordinal categorical data handling and strict type validation. The methodology involved automated unit testing and practical application on a real-world Spotify dataset. Results confirm the library's mathematical precision and effectiveness in exploratory data analysis, demonstrating the granular control provided by customized native algorithms without external dependencies.*

Resumo. *Este relatório apresenta a biblioteca "Dende Statistics", desenvolvida em Python nativo para mineração de dados. O foco reside na implementação de operadores estatísticos e lógicos de tendência central, dispersão, frequências e probabilidades. A ferramenta destaca-se pelo tratamento de dados categóricos ordinais e rigorosa validação de tipos. A metodologia incluiu testes unitários automatizados e aplicação prática sobre um dataset real do Spotify. Os resultados confirmam a precisão matemática e a eficácia da biblioteca na análise exploratória de dados, demonstrando o controle granular proporcionado por algoritmos customizados sem dependências externas.*

1. Introdução

A mineração de dados demanda o tratamento rigoroso de grandes volumes de informação, enfrentando o desafio da dependência de bibliotecas externas que podem ocultar inconsistências lógicas em variáveis categóricas e ordinais. O objetivo central deste trabalho é apresentar a biblioteca "Dende Statistics", desenvolvida em Python nativo para realizar a Análise Exploratória de Dados (AED), permitindo validar a integridade e o comportamento das variáveis antes da aplicação de modelos complexos. Este relatório detalha a fundamentação teórica e as equações dos operadores na Seção 2, a metodologia de implementação e validação na Seção 3, os resultados práticos obtidos

através de testes unitários e o uso de um dataset do Spotify na Seção 4, concluindo com as considerações finais na Seção 5.

2. Fundamentação Teórica

As métricas de mineração de dados são fundamentais para descrever o comportamento de variáveis numéricas e categóricas. Abaixo, detalham-se as classificações, equações e aplicações de cada operador presente na classe Statistics.

2.1. Métricas de Tendência Central

Estas métricas buscam um valor representativo do centro da distribuição dos dados.

Média Aritmética: Soma de todos os valores dividida pela quantidade de elementos. É aplicada para identificar o valor médio de atributos como a popularidade no Spotify.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Mediana: Valor central que divide o conjunto ordenado. Para dados qualitativos ordinais como a coluna `priority`, o operador utiliza um mapeamento numérico para definir a posição central.

$$\begin{aligned} \text{Se } n \text{ é ímpar: } \text{Mediana} &= x_{(\frac{n+1}{2})} \\ \text{Se } n \text{ é par: } \text{Mediana} &= \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2} \end{aligned}$$

Moda: Valor com maior frequência absoluta no conjunto. É a única métrica de tendência central aplicável a dados nominais puros, como o tipo de álbum (`album_type`).

2.2. Métricas de Dispersão e Posição

Indicam o quão afastados os dados estão do centro ou como se distribuem em subconjuntos.

Variância: Média do quadrado dos desvios em relação à média

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

Desvio Padrão: Raiz quadrada da variância, retornando a dispersão à unidade original dos dados

$$\sigma = \sqrt{\sigma^2}$$

Quartis: Valores que dividem os dados em quatro partes iguais (25%, 50%, 75%). O operador utiliza interpolação linear para determinar as posições exatas.

$$P_k = \frac{k(n+1)}{4}, \quad \text{para } k \in \{1, 2, 3\}$$

Histograma: Agrupamento de dados em intervalos (bins). O cálculo baseia-se na amplitude total dividida pelo número de intervalos:

$$H = \frac{\max(x) - \min(x)}{\text{bins}}.$$

2.3. Métricas de Relação, Frequência e Probabilidade Analisam a interação entre variáveis e a recorrência de eventos.

Covariância: Indica a direção da relação linear entre duas variáveis, como popularidade e número de seguidores:

$$\text{cov}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n}$$

Frequência Relativa: Proporção de uma categoria em relação ao total.

$$f_r = \frac{\text{frequência absoluta}}{n}$$

Probabilidade Condicional: Calculada com base na sequência temporal ou posicional dos dados no dataset, determinando a chance de o evento A ocorrer dado que B ocorreu anteriormente:

$$P(A|B) = \frac{\text{Contagem da sequência } (B, A)}{\text{Contagem total de } B}$$

3. Metodologia

A implementação da biblioteca baseou-se no paradigma de Orientação a Objetos, utilizando a linguagem Python em sua versão nativa. Esta escolha permitiu o

desenvolvimento de algoritmos customizados que garantem o controle total sobre a manipulação dos dados, sem a necessidade de pacotes externos.

3.1. Validação de Restrições do Dataset

Para assegurar a integridade da Análise Exploratória de Dados, o método construtor (init) da classe Statistics executa verificações de restrições fundamentais. O código valida se o dataset de entrada é um dicionário e se todas as colunas (listas) possuem exatamente o mesmo comprimento. Esta etapa é crítica para métricas que dependem da relação entre variáveis, como a covariância e a probabilidade condicional, onde a disparidade no tamanho das colunas invalidaria a análise.

3.2. Validação do Tipo de Dados para Execução

A biblioteca implementa uma validação de tipos em dois níveis:

Homogeneidade: No momento da inicialização, verifica-se se todos os itens de uma coluna pertencem ao mesmo tipo primitivo, evitando falhas silenciosas durante o processamento.

Especificidade Numérica: Métodos que envolvem operações aritméticas, como mean, variance e stdev, verificam explicitamente se os dados são numéricos (int ou float). Caso a coluna contenha dados não numéricos, o sistema interrompe a execução com um erro descritivo, prevenindo cálculos matemáticos em strings ou booleanos.

3.3. Implementação das Métricas e Reuso de Código

A arquitetura foi projetada para maximizar o reuso de código, o que reduz a redundância e o potencial de erros. Exemplos notáveis incluem:

Encadeamento Matemático: O método stdev (desvio padrão) invoca internamente o método variance, que por sua vez utiliza o método mean.

Frequências: O cálculo da relative_frequency reaproveita os resultados da absolute_frequency, aplicando apenas a normalização pelo total de elementos.

Cálculos Complexos: A implementação dos quartis utiliza uma função interna de interpolação linear para determinar valores entre índices, enquanto o histograma calcula dinamicamente a largura de cada intervalo (bin) com base na amplitude total dos dados.

3.4. Tratamento de Dados Categóricos Ordinais

Uma solução específica foi desenvolvida para lidar com dados ordinais (categorias com hierarquia). Para a coluna "priority", o código utiliza dicionários de mapeamento que

convertem etiquetas textuais em valores numéricos (ex: "baixa" -> 0, "media" -> 1, "alta" -> 2). Esta lógica permite que os métodos `median` e `cumulative_frequency` realizem ordenações baseadas no valor semântico das categorias, assegurando que o resultado estatístico reflita a realidade dos dados.

4. Resultados

A validação da biblioteca foi estruturada para garantir que os operadores lógicos e estatísticos implementados operem com precisão tanto em ambientes controlados quanto em grandes volumes de dados reais.

4.1. Resultados dos Testes Unitários

A classe `TestStatistics` foi utilizada para executar testes unitários em um dataset sintético de eventos, cobrindo 14 cenários distintos. A utilização do framework `unittest` permitiu confirmar que:

Precisão de Tendência Central: A média de participantes foi validada em 113,5 e a mediana em 105,0, demonstrando o funcionamento correto do tratamento de listas com número par de elementos.

Tratamento de Dados Ordinais: O teste da mediana para a coluna `priority` retornou o valor "media", comprovando que o mapeamento customizado ("baixa" < "media" < "alta") foi executado com sucesso.

Integridade de Dispersão e Relação: A variância do preço dos ingressos (525,25) e a covariância entre participantes e preço (1212,25) foram confirmadas, validando as fórmulas de somatório implementadas.

Frequência e Probabilidade: O sistema calculou corretamente a probabilidade condicional de 0,5 para a sequência "media -> alta", além de gerar frequências acumuladas absolutas e relativas consistentes para todas as categorias.

4.2. Aplicação na Base de Dados Spotify

Para testar o desempenho da biblioteca em um ambiente de mineração de dados real, as métricas foram aplicadas ao arquivo `spotify_data_clean.csv`. Esta etapa validou a capacidade da classe `Statistics` em lidar com o carregamento de dados via CSV e a conversão de tipos em tempo de execução.

Os resultados extraídos da base do Spotify incluíram:

Análise de Popularidade: O cálculo da média e do desvio padrão para `track_popularity` permitiu identificar a dispersão do sucesso das faixas no dataset.

Perfil do Álbum: Através do `itemset` e da `absolute_frequency`, identificou-se a predominância de tipos específicos de álbuns, fornecendo uma visão clara da composição do catálogo analisado.

Padrões de Sequência: O operador de probabilidade condicional foi utilizado para determinar a chance de uma música do tipo "single" aparecer logo após um "album" na lista, revelando padrões de organização da base.

Distribuição de Faixas: O histograma de popularidade dividiu as faixas em 5 intervalos (*bins*), facilitando a identificação de nichos de popularidade (ex: músicas com popularidade entre 20-40 vs 80-100).

5. Considerações Finais

O desenvolvimento da biblioteca **Dende Statistics** permitiu o cumprimento integral dos objetivos de aprendizagem propostos, demonstrando que a implementação manual de operadores estatísticos é um exercício fundamental para a compreensão profunda da mineração de dados. Ao construir cada métrica em Python nativo, foi possível observar "por baixo do capô" como os algoritmos lidam com a ordenação, a dispersão e as relações probabilísticas entre variáveis.

Os principais desafios técnicos enfrentados envolveram a implementação da **interpolação linear** para o cálculo preciso de quartis e a gestão da **prioridade semântica** em dados categóricos ordinais. Garantir que o código fosse resiliente a erros de tipagem e inconsistências no tamanho das colunas exigiu um planejamento rigoroso da arquitetura da classe, o que reforçou a importância da validação de dados na fase de pré-processamento.

Para trabalhos futuros e melhorias da ferramenta, identificaram-se pontos que podem elevar o nível de sofisticação da análise:

Visualização Gráfica: Integração de métodos para geração de gráficos em formato ASCII ou exportação para formatos visuais, facilitando a interpretação dos resultados do histograma e dos quartis.

Métricas de Correlação: Inclusão de coeficientes de Pearson ou Spearman para quantificar a força das relações identificadas pela covariância.

6. Referências

- HAN, Jiawei; KAMBER, Micheline; PEI, Jian. *Mineração de Dados: conceitos e técnicas*. 3. ed. Rio de Janeiro: Elsevier, 2012.
- BUSSAB, Wilton de Oliveira; MORETTIN, Pedro Alberto. *Estatística Básica*. 9. ed. São Paulo: Saraiva, 2017.
- TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. *Introdução ao Data Mining*. 1. ed. Rio de Janeiro: Ciência Moderna, 2009.
- RAMALHO, Luciano. *Python Fluente: Programação Clara, Concisa e Eficaz*. 1. ed. São Paulo: Novatec, 2015.
- PYTHON SOFTWARE FOUNDATION. *Python Language Reference, version 3.x*. Disponível em: <https://docs.python.org/3/>. Acesso em: 20 fev. 2026.